

## PROCESSAMENTO DE LINGUAGEM NATURAL

---

*Trabalho de Pesquisa*

# Transformers e o Mecanismo de Atenção

## Do Paper "Attention Is All You Need" às Aplicações Modernas

### Informações do Trabalho

**Disciplina:** Processamento de Linguagem Natural

**Tipo:** Pesquisa Individual

**Formato:** Artigo científico / Relatório técnico

**Entrega:** Notebook Jupyter + Documento escrito (PDF ou DOCX)

## 1. Apresentação do Trabalho

---

Este trabalho de pesquisa propõe uma investigação aprofundada sobre a arquitetura **Transformer** e seu mecanismo de atenção, apresentados no paper seminal "*Attention Is All You Need*" (Vaswani et al., 2017). Trata-se de uma das publicações mais influentes da história recente da Inteligência Artificial, com mais de 100.000 citações e impacto direto em modelos como BERT, GPT, T5, LLaMA e Claude.

O trabalho combina **pesquisa bibliográfica**, **compreensão conceitual** e **experimentação prática** com código Python, exigindo que o aluno não apenas reproduza definições, mas **demonstre compreensão real** ao implementar, adaptar e analisar criticamente os conceitos estudados.

### Objetivo geral

Investigar o mecanismo de atenção e a arquitetura Transformer em profundidade, compreendendo seus fundamentos teóricos, implementação prática e impacto no estado da arte do PLN — e desenvolver uma aplicação original que demonstre esse entendimento.

## 2. Tópicos de Pesquisa

O trabalho é organizado em **cinco eixos temáticos progressivos**. Cada eixo aprofunda o anterior e deve ser coberto no documento escrito e/ou no notebook de demonstração.

### Tópico 1 — Contexto Histórico e Motivação

*Por que o Transformer foi necessário? O que havia de limitado antes?*

- **Evolução dos modelos de linguagem:** de n-gramas e modelos estatísticos até redes neurais
- **Limitações das RNNs e LSTMs:** processamento sequencial, vanishing gradient, dificuldade com contexto longo
- **O paper de 2017:** autores, contexto institucional (Google Brain), contribuições e recepção inicial
- **Comparação de paradigmas:** RNN vs CNN vs Atenção — tabela de vantagens e limitações
- **Impacto científico:** número de citações, modelos derivados, linha do tempo 2017–2024

#### Questão norteadora do Tópico 1

"O que tornava o processamento de linguagem difícil antes de 2017 e como o Transformer atacou essas dificuldades de forma fundamentalmente diferente?"

### Tópico 2 — Fundamentos Teóricos do Mecanismo de Atenção

*Como a atenção funciona matematicamente? O que são Query, Key e Value?*

- **Atenção como mecanismo de recuperação de informação:** analogia com sistemas de busca
- **Scaled Dot-Product Attention:** fórmula, cada componente e por que dividir por  $\sqrt{d_k}$
- **Os vetores Q, K e V:** o que representam, como são gerados pelas matrizes  $W_Q$ ,  $W_K$ ,  $W_V$
- **Softmax e distribuição de probabilidade:** por que usar softmax e não apenas normalizar
- **Multi-Head Attention:** razão para múltiplas cabeças, concatenação, projeção final  $W_O$
- **Complexidade computacional:**  $O(n^2 \times d)$  vs  $O(n \times d^2)$  das RNNs — trade-off com comprimento da sequência

#### Atividade prática obrigatória do Tópico 2

Implementar a função `scaled_dot_product_attention()` com NumPy do zero, sem usar nenhuma biblioteca de deep learning. A implementação deve incluir comentários explicativos em cada linha e testes de verificação (ex: confirmar que os pesos somam 1.0).

### Tópico 3 — Arquitetura Completa do Transformer

*Como todas as peças se encaixam? O que é o Encoder e o Decoder?*

- **Positional Encoding:** funções sin/cos, propriedades, por que não usar embeddings treináveis de posição
- **Camada Transformer completa:** Multi-Head Attention → Add & Norm → FFN → Add & Norm
- **Conexões residuais (residual connections):** por que são indispensáveis para redes profundas
- **Layer Normalization vs Batch Normalization:** diferenças e por que LN é preferida em sequências
- **Encoder vs Decoder:** arquitetura do paper original para tradução — self-attention vs cross-attention
- **Encoder-only (BERT), Decoder-only (GPT), Encoder-Decoder (T5):** diferenças e casos de uso
- **Hiperparâmetros principais:** d\_model, n\_heads, d\_ff, n\_layers — impacto em capacidade e custo

### Questão norteadora do Tópico 3

"Se você precisasse explicar o Transformer para alguém sem formação em matemática, como descreveria cada componente usando apenas analogias do cotidiano?"

## Tópico 4 — Modelos Pré-treinados: BERT, GPT e Família

*Como o Transformer virou a base de todos os modelos modernos de linguagem?*

- **Transfer Learning em PLN:** pré-treinamento + fine-tuning — por que funciona tão bem
- **BERT (2018):** Masked Language Model, Next Sentence Prediction, bidirecionalidade, vocabulário WordPiece
- **GPT (2018–2023):** autoregressive language modeling, in-context learning, escalabilidade
- **Comparativo BERT vs GPT:** encoder-only vs decoder-only — tarefas de compreensão vs geração
- **Variantes eficientes:** DistilBERT, ALBERT, RoBERTa, DeBERTa — o que cada uma otimiza
- **Modelos para Português:** BERTimbau, Sabiá, Maritaca — corpus, avaliação, benchmarks
- **Large Language Models (LLMs):** GPT-4, Gemini, LLaMA, Claude — escala e capacidades emergentes

### Atividade prática obrigatória do Tópico 4

Usar o Hugging Face para carregar dois modelos (um encoder-only e um decoder-only), executar uma mesma tarefa com cada um e comparar os resultados. Documentar diferenças observadas e explicar por que cada arquitetura se comporta de forma diferente para a tarefa escolhida.

## Tópico 5 — Aplicação Original e Análise Crítica

*O que você consegue construir com o que aprendeu? Quais são os limites desta tecnologia?*

- **Desenvolvimento de uma aplicação própria:** classificação, geração, sumarização, tradução, QA ou outra tarefa
- **Análise dos pesos de atenção:** visualizar e interpretar o que o modelo "olha" para uma entrada específica
- **Experimento de ablation:** remover ou modificar componentes e medir o impacto na performance
- **Limitações e críticas:** complexidade quadrática, custo computacional, viés dos dados de treino
- **Direções de pesquisa ativas:** Efficient Transformers (Longformer, Performer, FlashAttention), Sparse Attention
- **Impacto social e ético:** alucinações, desinformação, consumo energético, democratização vs concentração
- **Reflexão pessoal:** o que surpreendeu? O que mudaria na arquitetura se pudesse? Qual pergunta aberta mais intriga?

### Questão norteadora do Tópico 5

"O Transformer é a arquitetura final para PLN, ou é um degrau em direção a algo mais poderoso? Que evidências sustentam sua resposta?"

### 3. Estrutura do Documento Escrito

O trabalho deve ser entregue como um **artigo técnico-científico** seguindo a estrutura abaixo. O tamanho mínimo é **12 páginas** (excluindo capa, sumário e referências), com no máximo 20 páginas.

| Seção                   | Conteúdo esperado                                                  | Tamanho    |
|-------------------------|--------------------------------------------------------------------|------------|
| 1. Introdução           | Contexto, motivação, objetivo do trabalho e estrutura do documento | 1–2 pág.   |
| 2. Fundamentação        | Revisão da literatura — RNNs, atenção, paper original comentado    | 2–3 pág.   |
| 3. Mecanismo de atenção | Explicação detalhada de Q, K, V, MHA, PE, Add&Norm, FFN            | 2–3 pág.   |
| 4. Modelos pré-treino   | BERT, GPT, família — comparativo, BERTimbau, benchmarks            | 2–3 pág.   |
| 5. Implementação        | Descrição do que foi implementado no notebook + resultados         | 2–3 pág.   |
| 6. Análise crítica      | Limitações, direções futuras, reflexão pessoal                     | 1–2 pág.   |
| 7. Conclusão            | Síntese dos achados e resposta à questão norteadora geral          | 0.5–1 pág. |
| 8. Referências          | Mínimo 8 referências (papers, livros, documentações)               | variável   |

#### 3.1 Notebook Jupyter Complementar

O notebook deve conter **código funcional e comentado** cobrindo:

1. Implementação do Scaled Dot-Product Attention com NumPy (do zero)
2. Visualização de Positional Encoding (heatmap e curvas por dimensão)
3. Demonstração de Multi-Head Attention com pelo menos 4 cabeças
4. Modelo Transformer treinável com Keras para uma tarefa à escolha
5. Extração e visualização de pesos de atenção de um modelo real (BERT/DistilBERT)
6. Comparativo quantitativo: modelo Transformer vs modelo RNN/LSTM na mesma tarefa
7. [OPCIONAL +2 pts] Aplicação original fine-tunada para um dataset em Português

#### 3.2 Formatação do Documento

| Elemento       | Especificação                                                  |
|----------------|----------------------------------------------------------------|
| Fonte do corpo | Arial ou Times New Roman, tamanho 11 ou 12                     |
| Espaçamento    | 1,5 entre linhas no corpo; simples em citações longas e código |
| Margens        | 2,5 cm em todos os lados                                       |
| Citações       | ABNT NBR 6023 ou APA (escolha um e mantenha consistência)      |

|                    |                                                              |
|--------------------|--------------------------------------------------------------|
| Figuras/Tabelas    | Todas devem ter legenda numerada e ser citadas no texto      |
| Idioma             | Português Brasileiro (termos técnicos em inglês são aceitos) |
| Formato de entrega | PDF + .ipynb compactados em .zip nomeado NOME_TRABALHO.zip   |

## 4. Referências Bibliográficas de Apoio

---

### Papers Fundamentais

- **Vaswani, A. et al. (2017).** *Attention Is All You Need*. NeurIPS. arXiv:1706.03762
- **Devlin, J. et al. (2018).** *BERT: Pre-training of Deep Bidirectional Transformers*. arXiv:1810.04805
- **Radford, A. et al. (2018).** *Improving Language Understanding by Generative Pre-Training*. OpenAI Blog
- **Brown, T. et al. (2020).** *Language Models are Few-Shot Learners (GPT-3)*. NeurIPS. arXiv:2005.14165
- **Souza, F. et al. (2020).** *BERTimbau: Pretrained BERT Models for Brazilian Portuguese*. BRACIS 2020

### Livros e Recursos Online

- **Tunstall, L. et al. (2022).** *Natural Language Processing with Transformers*. O'Reilly — disponível gratuitamente em: [huggingface.co/course](https://huggingface.co/course)
- **Alammar, J. (2018).** *The Illustrated Transformer*. [jalammar.github.io/illustrated-transformer](https://jalammar.github.io/illustrated-transformer)
- **Hugging Face Docs.** [huggingface.co/docs/transformers](https://huggingface.co/docs/transformers)
- **d2l.ai — Dive into Deep Learning.** Capítulo 11: Attention Mechanisms. [d2l.ai/chapter\\_attention-cues](https://d2l.ai/chapter_attention-cues)

### Ferramentas para Análise de Atenção

- **BertViz:** [github.com/jessevig/bertviz](https://github.com/jessevig/bertviz) — visualização interativa de atenção
- **Transformers Interpret:** [github.com/cdpierse/transformers-interpret](https://github.com/cdpierse/transformers-interpret)
- **LM Head Visualizer:** disponível no Hugging Face Spaces

---

*Boa pesquisa — o Transformer é uma das arquiteturas mais elegantes da computação moderna.*