

GABARITO

Aula 6 — Aplicações de PLN

Tradução Automática · Sumarização · Análise de Sentimento

Bloco A — Tradução Automática

Questão 1 — Evolução da Tradução Automática

Resposta esperada

O aluno deve descrever as três fases e as motivações de cada transição:

1. BASEADA EM REGRAS (1950–1980): dicionários bilíngues + regras gramaticais programadas manualmente. Vantagem: interpretável. Limitação: não escala — cada novo par de idiomas exige trabalho manual imenso.
2. ESTATÍSTICA — SMT (1990–2014): aprende alinhamentos em corpora paralelos. Vantagem: data-driven, elimina regras manuais. Limitação: trabalha com fragmentos de texto sem compreensão semântica; gargalo no alinhamento de palavras.
3. NEURAL — NMT com seq2seq (2014–2017): rede neural aprende representações end-to-end. Vantagem: captura dependências longas, melhor qualidade. Limitação: gargalo do vetor de contexto fixo que "comprime" toda a frase de origem.
4. TRANSFORMER (2017–hoje): atenção cruzada permite que o decoder acesse diretamente qualquer parte da frase de origem. Elimina o gargalo e processa em paralelo. Qualidade próxima a tradutores humanos em pares com muitos dados.

Questão 2 — Encoder-Decoder e Atenção Cruzada

Resposta esperada

O aluno deve explicar:

ENCODER: lê o texto de origem (PT) e produz representações contextuais para cada token.

DECODER: gera o texto de destino (EN) token por token, consultando o encoder a cada passo.

LIMITAÇÃO DO VETOR FIXO (seq2seq original):

O encoder comprimia toda a frase de origem em um único vetor — independentemente do tamanho da frase. Frases longas sofriam perda de informação. O decoder não sabia "onde olhar" no texto de origem.

SOLUÇÃO — ATENÇÃO CRUZADA (cross-attention):

Em cada passo de geração, o decoder pode calcular um peso de atenção para CADA token do encoder. Ao traduzir "cachorro", o decoder presta alta atenção no token "dog" da frase de origem. Isso elimina o gargalo e melhora drasticamente a qualidade em frases longas.

Questão 3 — Métrica BLEU

Resposta esperada

O aluno deve explicar os três componentes:

1. CÁLCULO: BLEU mede a precisão de n-gramas (sequências de n palavras). Para cada valor de n (1, 2, 3, 4), calcula-se quantos n-gramas da tradução do modelo aparecem na tradução de referência. O score final é a média geométrica dos quatro valores, multiplicada por uma penalidade de brevidade (BP) que pune traduções muito curtas.

2. INTERPRETAÇÃO: escala de 0 a 100. Abaixo de 10 = incompreensível; 20-30 = aceitável; acima de 30 = bom; acima de 50 = qualidade profissional.

3. LIMITAÇÕES (o aluno deve citar pelo menos 2):

- Não captura sinônimos: "bonito" e "lindo" são diferentes para o BLEU
- Sensível a uma única referência: traduções criativas mas corretas são penalizadas
- Não mede fluência ou gramática diretamente
- Correlação imperfeita com julgamento humano em algumas línguas

Bloco B — Sumarização Automática

Questão 4 — Extrativa vs Abstrativa

Resposta esperada

EXTRATIVA: seleciona e copia frases do texto original. Fidedigna (nunca inventa) mas pode ser desconectada.

→ Cenário ideal: documentos legais, contratos, laudos médicos — onde precisão factual é crítica e nenhuma paráfrase é aceitável.

ABSTRATIVA: gera novas frases reescrevendo o conteúdo. Fluente e coesa, mas pode "alucinar".

→ Cenário ideal: resumo de notícias, artigos científicos para o público geral, boletins executivos — onde fluência e concisão são mais importantes que reprodução literal.

O aluno deve demonstrar compreensão de que a escolha depende do trade-off entre fidelidade factual e qualidade da leitura.

Questão 5 — Pré-treinamento com Ruído do BART

Resposta esperada

PRÉ-TREINAMENTO COM RUÍDO:

O BART corrompe textos de diversas formas (mascaramento de tokens, remoção de sentenças, embaralhamento da ordem, rotação de documentos) e treina o modelo para reconstruir o texto original. Isso força o modelo a aprender representações ricas do conteúdo.

POR QUE É EFICAZ PARA SUMARIZAÇÃO:

A tarefa de reconstruir um documento corrompido a partir de um texto degradado é estruturalmente similar ao resumo: em ambos, o modelo precisa capturar a essência do texto de entrada e gerar uma saída coerente. O pré-treinamento prepara o modelo para essa tarefa de forma muito eficiente.

FINE-TUNING:

Com um dataset de pares (artigo, resumo) como CNN/DailyMail, o BART é ajustado para gerar resumos específicos. Os pesos são atualizados com taxa de aprendizado pequena para preservar o conhecimento do pré-treinamento.

Questão 6 — Alucinações em Modelos Abstrativistas

Resposta esperada

DEFINIÇÃO: alucinação ocorre quando o modelo gera informação factualmente incorreta ou não presente no texto de entrada.

POR QUE OCORRE:

- O modelo aprende padrões estatísticos de como textos são escritos, não fatos do mundo
- Durante a geração, o decoder pode priorizar fluência em detrimento da fidelidade
- O modelo interpola informações vistas no treinamento com o conteúdo do input

IMPACTOS EM APLICAÇÕES REAIS:

- Resumos médicos com diagnósticos inventados
- Resumos jurídicos com cláusulas não presentes no contrato
- Notícias com fatos distorcidos

FORMAS DE MITIGAÇÃO:

- Usar sumarização extrativa para domínios críticos
- Aplicar métricas de fidelidade factual (FactCC, QAFactEval)
- Usar modelos treinados especificamente para fidelidade
- Revisão humana para conteúdo crítico

Bloco C — Análise de Sentimento

Questão 7 — Três Abordagens Comparadas

Resposta esperada

LÉXICO: words têm scores fixos. Vantagem: sem treino, rápido, interpretável. Limitação: sem contexto, negação, ironia. Usar quando: sem dados rotulados, interpretabilidade crítica.

ML CLÁSSICO (SVM, Naive Bayes + TF-IDF): aprende padrões de features. Vantagem: funciona com poucos dados, rápido de treinar. Limitação: features manuais, sem semântica. Usar quando: dataset pequeno (< 1.000 exemplos), recursos computacionais limitados.

DEEP LEARNING (BERT): atenção bidirecional captura contexto completo. Vantagem: estado da arte, captura negação, ironia, domínio. Limitação: GPU necessária, muitos dados para fine-tuning. Usar quando: alto volume, alta precisão necessária, dados disponíveis.

O aluno deve demonstrar que a melhor abordagem depende dos recursos e requisitos do projeto — não existe "melhor em geral".

Questão 8 — Negação como Desafio

Resposta esperada

EXEMPLOS DE NEGAÇÃO INVERTENDO SENTIMENTO:

1. "O produto não é bom" → sem negação: "bom"=positivo; com negação=negativo
2. "Nunca mais compro nesta loja" → "compro" e "loja" são neutras; "nunca mais" inverte

POR QUE LÉXICO FALHA:

Um sistema léxico soma os scores das palavras individualmente. "Não" tem score próximo de 0, então "não excelente" recebe o score positivo de "excelente". O contexto de negação é ignorado.

COMO BERT LIDA MELHOR:

O BERT processa a frase inteira com atenção bidirecional. O token "bom" recebe alta atenção do token "não", modificando sua representação vetorial. O modelo aprende durante o fine-tuning que "não bom" tem representação similar a "ruim". A bidirecionalidade é fundamental — ao processar "bom", o BERT já "viu" o "não" que vem antes.

Questão 9 — F1-Score vs Accuracy

Resposta esperada

PROBLEMA DA ACCURACY EM DATASETS DESBALANCEADOS:

Exemplo: Dataset com 900 reviews positivos e 100 negativos (total: 1.000).

Modelo que classifica TUDO como positivo:

- Accuracy = $900/1000 = 90\%$ ← parece ótimo!
- Mas nunca detecta reviews negativos

F1-Score desse modelo:

Precisão (positivo): $900/1000 = 90\%$

Recall (positivo): $900/900 = 100\%$

F1 positivo: $2 \times (0.9 \times 1.0) / (0.9 + 1.0) = 0.947$

F1 negativo: 0 (nunca prevê negativo $\rightarrow$ recall=0)

Macro-F1 = $(0.947 + 0) / 2 = 0.47$ $\leftarrow$ expõe o problema!

O F1-Score é a média harmônica de Precisão e Recall.

O Macro-F1 calcula o F1 para cada classe e faz a média — punindo fortemente quando uma classe é ignorada.

Bloco D — Integração

Questão 10 — Pipeline de Monitoramento de Notícias

Resposta esperada

O aluno deve propor um pipeline com pelo menos as etapas abaixo:

ETAPA 1 — COLETA

Ferramentas: RSS feeds, NewsAPI, scrapers
Filtro por palavras-chave do setor da empresa

ETAPA 2 — SUMARIZAÇÃO (inglês → inglês)

Modelo: BART (facebook/bart-large-cnn)
max_length=80, min_length=30
Avaliação: ROUGE-1/2 vs resumos humanos de referência

ETAPA 3 — TRADUÇÃO (inglês → português)

Modelo: Helsinki-NLP/opus-mt-tc-big-en-pt
Avaliação: BLEU vs tradução humana de referência

ETAPA 4 — ANÁLISE DE SENTIMENTO (português)

Modelo: lxyuan/distilbert-base-multilingual-cased-sentiments
Classes: positivo / neutro / negativo
Avaliação: Macro-F1 em dataset rotulado do setor

ETAPA 5 — GERAÇÃO DO BOLETIM

Agrupamento por sentimento e tema
Ordenação por relevância (score de atenção + sentimento)
Formatação em template PT-BR

AVALIAÇÃO DO SISTEMA:

Avaliação end-to-end por jornalistas ou analistas do setor
Métricas por etapa: ROUGE (sumarização), BLEU (tradução), F1 (sentimento)
Monitoramento de drift (qualidade degradando ao longo do tempo)

NOTA: respostas que mencionem trade-offs (ex: qualidade vs velocidade, custo de API vs modelo local) devem receber bônus.

Questão	Conceito central avaliado
Q1	Evolução histórica — abordagens e motivações
Q2	Encoder-Decoder e atenção cruzada
Q3	Métricas BLEU — cálculo, interpretação e limites
Q4	Extrativa vs abstrativa — quando usar cada
Q5	BART — pré-treinamento com ruído e fine-tuning
Q6	Alucinações — causas, impactos e mitigação

Q7	Três abordagens — comparativo crítico
Q8	Negação — desafio e como BERT o resolve
Q9	F1 vs Accuracy — exemplo numérico
Q10	Pipeline integrado — projeto completo