

PROCESSAMENTO DE LINGUAGEM NATURAL

Material Complementar Teórico

Aula 6

Aplicações de PLN

Tradução Automática · Sumarização · Análise de Sentimento

Objetivos de Aprendizagem

Ao concluir a leitura deste material, você será capaz de:

- Explicar o funcionamento da tradução automática neural e suas métricas de avaliação
- Distinguir entre sumarização extrativa e abstrativa, com exemplos de uso
- Descrever a arquitetura Encoder-Decoder e sua aplicação em tradução e sumarização
- Compreender os fundamentos da análise de sentimento e suas abordagens
- Identificar as principais métricas de avaliação em cada tarefa de PLN
- Avaliar criticamente limitações e desafios de cada aplicação
- Propor pipelines multimodais combinando as três aplicações estudadas

1. Tradução Automática Neural

1.1 Evolução Histórica


A tradução automática percorreu um longo caminho desde suas origens. Na década de 1950, os primeiros sistemas eram baseados em **dicionários bilíngues e regras gramaticais** programadas manualmente — uma abordagem trabalhosa e de qualidade limitada. Nos anos 1990, os sistemas **estatísticos** passaram a dominar, aprendendo padrões de alinhamento em grandes corpora paralelos.

A revolução definitiva veio com as **redes neurais**. Em 2014, o modelo **seq2seq** (sequence-to-sequence) mostrou que uma rede neural poderia aprender a traduzir end-to-end, sem regras explícitas. Em 2017, o Transformer consolidou essa abordagem, tornando a tradução neural o padrão da indústria.

Época	Abordagem	Exemplo	Limitação
1950–1980	Baseada em regras	Dicionários + gramáticas manuais	Não escala para idiomas novos
1990–2014	Estatística (SMT)	IBM Models, Moses	Necessita alinhamento manual de corpus
2014–2017	Redes neurais (NMT)	seq2seq com LSTM	Gargalo no vetor de contexto fixo
2017–hoje	Transformer (NMT)	Helsinki-NLP, DeepL	Custo computacional elevado

1.2 Arquitetura Encoder-Decoder

O modelo seq2seq introduziu a arquitetura **Encoder-Decoder**, que permanece como base de todos os modelos modernos de tradução:



No modelo Transformer, essa arquitetura foi aprimorada com o **mecanismo de atenção cruzada** (cross-attention): o Decoder pode "prestar atenção" diretamente em qualquer parte do texto de origem em cada passo de geração, eliminando o gargalo do vetor de contexto fixo.

1.3 Métricas de Avaliação — BLEU Score

A métrica mais usada para avaliar tradução automática é o **BLEU** (Bilingual Evaluation Understudy), proposto por Papineni et al. (2002). O BLEU mede o quanto os **n-gramas** (sequências de n palavras) do texto traduzido aparecem na tradução de referência humana.

Como o BLEU funciona (simplificado)

Referência humana: "The cat sat on the mat"

Tradução do modelo: "The cat is on the mat"

Unigramas (1-gram) em comum: The, cat, on, the, mat = $5/6 = 83\%$

Bigramas (2-gram) em comum: "The cat", "on the", "the mat" = $3/5 = 60\%$

BLEU final: média geométrica dos n-gramas (com penalidade por brevidade)

Escala: 0 a 100 — acima de 30 é considerado bom

Score BLEU	Qualidade da tradução
< 10	Quase incompreensível
10–19	Compreensível, mas com muitos erros
20–29	Aceitável, erros notáveis
30–40	Boa qualidade para a maioria dos usos
40–50	Alta qualidade, comparável a tradutores humanos
> 50	Qualidade profissional ou melhor

1.4 Back-Translation — Avaliação Prática

A **back-translation** (retro-tradução) é uma técnica simples para avaliar qualitativamente uma tradução: traduz-se o texto na direção $A \rightarrow B$ e depois $B \rightarrow A$, comparando o resultado com o texto original. Se o significado se preservou, a tradução foi bem-sucedida.

Além da avaliação, a back-translation é usada para **aumentar dados de treinamento**: textos monolíngues no idioma alvo são traduzidos para o idioma de origem, gerando pares de treino sintéticos e melhorando a qualidade do modelo.

1.5 Limitações da Tradução Automática

- **Ambiguidade lexical**: "banco" pode ser móvel ou instituição financeira — o modelo precisa do contexto
- **Expressões idiomáticas**: "estar com a faca e o queijo na mão" não tem equivalente literal
- **Línguas de baixo recurso**: idiomas com pouco dado paralelo têm qualidade muito inferior
- **Domínios especializados**: termos médicos, jurídicos ou técnicos exigem modelos específicos
- **Preservação de registro**: formalidade, ironia e humor são difíceis de preservar

2. Sumarização Automática de Textos

2.1 Definição e Tipos

Sumarização automática é a tarefa de produzir automaticamente uma **versão condensada** de um ou mais textos, preservando as informações mais relevantes. Existem dois tipos fundamentais:

Tipo	Como funciona	Vantagem	Desvantagem
Extrativa	Seleciona e copia frases do texto original	Fidedigna — nunca inventa informação	Resumos podem ser desconexos ou repetitivos
Abstrativa	Gera novas frases com o conteúdo do texto	Fluente e coesa, como um humano resumiria	Pode gerar "alucinações" (informação inventada)

Modelos modernos como BART e T5 usam **sumarização abstrativa** baseada em Transformers. Eles não se limitam a copiar frases — reescrevem o conteúdo de forma coesa e fluente, como um humano faria ao resumir um texto.

2.2 O Modelo BART

BART = Bidirectional and Auto-Regressive Transformers (Lewis et al., 2020)

O BART combina as melhores características do BERT e do GPT em um único modelo Encoder-Decoder:

- **Encoder bidirecional (como BERT):** lê e compreende o texto de entrada com atenção bidirecional
- **Decoder autorregressivo (como GPT):** gera o resumo token por token, da esquerda para a direita
- **Pré-treino com ruído:** o modelo aprende a reconstruir textos corrompidos — deletados, embaralhados, mascarados

Pré-treinamento do BART:

Texto original: "Natural language processing is fascinating"

Texto corrompido: "language [MASK] is [DELETED] fascinating natural"

BART aprende: reconstruir o texto original a partir do corrompido

Fine-tuning para sumarização:

Entrada: artigo longo

Saída: resumo conciso

Dataset: CNN/DailyMail (300k pares artigo-resumo)

2.3 Parâmetros de Controle

Os principais parâmetros que controlam o comportamento da sumarização são:

Parâmetro	O que controla	Valor típico
-----------	----------------	--------------

max_length	Tamanho máximo do resumo em tokens	50–200 (curto a longo)
min_length	Tamanho mínimo (evita resumos triviais)	20–50
do_sample	True = aleatório / False = determinístico	False para reprodutibilidade
num_beams	Busca em feixe — qualidade vs velocidade	4 (padrão), 1 = greedy
length_penalty	> 1 favorece resumos mais longos	1.0 (neutro)

2.4 Métricas de Avaliação — ROUGE

A métrica padrão para sumarização é o **ROUGE** (Recall-Oriented Understudy for Gisting Evaluation), proposto por Lin (2004). Ao contrário do BLEU (que mede precisão), o ROUGE mede **recall** — quantas informações do resumo de referência foram capturadas.

Variante	O que mede	Fórmula simplificada
ROUGE-1	Sobreposição de unigramas (palavras)	Interseção / Total na referência
ROUGE-2	Sobreposição de bigramas	Bigramas em comum / Bigramas na referência
ROUGE-L	Maior subsequência comum (LCS)	LCS / Comprimento da referência

Exemplo de cálculo ROUGE-1

Referência: "O modelo BART resume textos longos de forma eficiente"

Resumo: "BART é um modelo eficiente para resumir textos"

Palavras em comum: BART, modelo, eficiente, textos = 4 palavras

Total na referência: 9 palavras

ROUGE-1 = $4/9 = 0.44$ (44%)

2.5 Desafios e Limitações

- **Alucinações:** modelos abstrativistas podem inventar fatos não presentes no texto original
- **Textos muito longos:** modelos têm limite de tokens (512–1024) — textos mais longos precisam ser segmentados
- **Preservação de nuances:** ironia, negação e contexto implícito podem ser perdidos no resumo
- **Domínio específico:** modelos treinados em notícias podem ter desempenho inferior em artigos científicos
- **Idiomas não-ingleses:** a maioria dos modelos de alta qualidade foi treinada em inglês

3. Análise de Sentimento

3.1 Definição e Escopo

A análise de sentimento (também chamada de **opinion mining**) é uma área do PLN que busca identificar, extrair e quantificar **opiniões, sentimentos e atitudes** expressas em textos. O objetivo central é classificar a **polaridade** de um texto — positivo, negativo ou neutro — embora versões mais avançadas identifiquem emoções específicas como alegria, raiva, tristeza ou surpresa.

3.2 Níveis de Análise

Nível	Descrição	Exemplo
Documento	Classifica o sentimento do texto inteiro	Review de produto: POSITIVO
Sentença	Classifica cada frase individualmente	"A câmera é ótima, mas a bateria é ruim" → [POS, NEG]
Aspecto	Identifica o sentimento por atributo específico	Câmera: positivo Bateria: negativo Preço: neutro
Palavra	Classifica cada palavra com carga emocional	"excelente"=+3, "terrível"=-3, "ok"=0

3.3 Abordagens para Análise de Sentimento

Abordagem 1 — Baseada em Léxicos (sem aprendizado)

Usa dicionários de polaridade (lexicons) onde cada palavra tem uma pontuação de sentimento. A pontuação do texto é a soma ou média das pontuações das palavras. Exemplos: SentiWordNet, VADER, OpinionLexicon.

```
Frase: "O produto é excelente mas a entrega foi terrível"
excelente → +3
terrível → -3
Score total = +3 + (-3) = 0 → NEUTRO

Limitação: não captura contexto ("não excelente" = positivo ou negativo?)
```

Abordagem 2 — Aprendizado de Máquina Clássico

Usa representações de texto (TF-IDF, BoW) como features para algoritmos como Naive Bayes, SVM ou Regressão Logística. Requer dados rotulados para treino e não captura ordem ou contexto.

Abordagem 3 — Deep Learning (estado da arte)

Modelos como BERT e suas variantes processam o texto inteiro com atenção bidirecional, capturando contexto, negação, ironia e nuances semânticas. São fine-tuned em datasets rotulados de sentimento.

Abordagem	Vantagem	Desvantagem	Exemplo
-----------	----------	-------------	---------

Léxico	Sem treino, interpretável	Não captura contexto	VADER, SentiWordNet
ML Clássico	Rápido, funciona com poucos dados	Features manuais, sem semântica	Naive Bayes + TF-IDF
Deep Learning	Alta precisão, captura nuances	Necessita GPU, muitos dados	BERT, RoBERTa, DistilBERT

3.4 Desafios da Análise de Sentimento

- **Negação:** "Não gostei nada" → sem negação seria positivo; com negação é negativo
- **Ironia e sarcasmo:** "Que ótimo serviço, esperei apenas 3 horas!" → positivo na superfície, negativo no sentido
- **Comparações:** "Este é melhor que o anterior" — comparativo não é necessariamente positivo
- **Domínio específico:** "Este filme é doentio!" pode ser positivo em contexto de cinema de terror
- **Multilinguagem:** modelos treinados em inglês têm queda de performance em outros idiomas
- **Subjetividade:** nem todo texto tem sentimento — notícias factuais são neutras mas não expressam opinião

4. Métricas de Avaliação — Resumo Comparativo

Tarefa	Métrica Principal	O que mede	Escala
Tradução	BLEU (0–100)	Precisão de n-gramas vs referência humana	> 30 = bom
Tradução	TER	Taxa de edições para corrigir a tradução	Menor = melhor
Sumarização	ROUGE-1/2/L	Recall de n-gramas vs resumo de referência	0–1 (mais alto = melhor)
Sumarização	BERTScore	Similaridade semântica com BERT embeddings	0–1
Sentimento	Accuracy	% de textos classificados corretamente	0–100%
Sentimento	F1-Score	Média harmônica de precisão e recall	0–1
Sentimento	Macro-F1	F1 médio sobre todas as classes	0–1

Por que F1-Score é preferido ao Accuracy?

Em datasets desbalanceados (ex: 90% positivos e 10% negativos), um modelo que classifica tudo como positivo teria 90% de accuracy — mas seria inútil para detectar negativos.

O F1-Score penaliza esse comportamento porque considera tanto a precisão (de todos que predisse como positivo, quantos realmente eram?) quanto o recall (de todos os positivos reais, quantos detectou?). Para análise de sentimento com classes desbalanceadas, sempre use F1-Score ou Macro-F1.

5. Pipelines Multimodais — Combinando as Três Tarefas

5.1 O Conceito de Pipeline em PLN

Um **pipeline** em PLN é uma sequência de modelos encadeados, onde a saída de cada etapa alimenta a próxima. A capacidade de combinar modelos especializados permite construir sistemas complexos com componentes simples e intercambiáveis.

```
Pipeline: Análise completa de notícia internacional

ENTRADA: artigo em inglês (500 palavras)
↓
ETAPA 1: BART → resumo em inglês (60 palavras)
↓
ETAPA 2: Helsinki EN→PT → resumo em português
↓
ETAPA 3: DistilBERT multilíngue → sentimento (positivo/negativo/neutro)
↓
SAÍDA: {resumo_pt, sentimento, confiança}
```

5.2 Casos de Uso Reais

Sistema	Tarefas combinadas	Aplicação
Monitor de mídia	Coleta + Sumarização + Sentimento	Marca saber o que a imprensa diz sobre ela
Feed multilíngue	Tradução + Sumarização	Ler notícias estrangeiras em PT
Central de atendimento	Sentimento + Classificação	Priorizar tickets negativos urgentes
Revisão de literatura	Sumarização + Classificação	Resumir e categorizar centenas de artigos
Monitor de redes sociais	Tradução + Sentimento + Tendências	Análise global de opinião em tempo real

5.3 Considerações de Propagação de Erros

Em pipelines encadeados, os erros se propagam e se amplificam. Se o sumariador gera um resumo impreciso, o classificador de sentimento vai analisar informação incorreta — gerando um resultado final ainda mais incorreto. Por isso é fundamental:

- **Avaliar cada etapa separadamente** antes de integrar ao pipeline
- **Monitorar a qualidade** em cada passo com métricas adequadas
- **Incluir fallbacks** para casos onde um modelo falha ou retorna baixa confiança
- **Considerar a ordem das tarefas** — em alguns casos, classificar sentimento antes de resumir pode ser mais robusto

6. Questões Dissertativas para Avaliação

As questões a seguir avaliam a compreensão teórica dos conteúdos desta aula. Responda com suas próprias palavras, demonstrando domínio conceitual e capacidade de análise crítica.

Orientações para a avaliação

- Cada questão vale 2 pontos — total de 20 pontos
- Respostas devem ser claras, objetivas e demonstrar compreensão conceitual
- Exemplos próprios são bem-vindos e valorizam a resposta
- Citações de modelos e métricas específicas demonstram domínio do conteúdo
- Respostas que apenas repetem definições sem análise própria recebem no máximo 60%

BLOCO A — Tradução Automática

1. **Questão 1.** Descreva a evolução da tradução automática desde os sistemas baseados em regras até os modelos neurais modernos baseados em Transformers. Quais foram os principais avanços em cada fase e quais limitações motivaram a transição para a abordagem seguinte?
2. **Questão 2.** Explique a arquitetura Encoder-Decoder utilizada na tradução automática neural. Qual é o papel do mecanismo de atenção cruzada (cross-attention) e como ele supera a limitação do vetor de contexto fixo dos modelos seq2seq originais?
3. **Questão 3.** O que é a métrica BLEU? Explique como ela é calculada, qual sua interpretação prática e quais são suas principais limitações como métrica de avaliação de tradução automática.

BLOCO B — Sumarização Automática

4. **Questão 4.** Diferencie sumarização extrativa de sumarização abstrativa. Para cada tipo, cite um exemplo de aplicação onde seria mais adequado utilizá-lo e justifique sua escolha.

5. **Questão 5.** O modelo BART foi treinado com uma técnica de pré-treinamento baseada em ruído. Descreva essa técnica, explique por que ela é eficaz para a tarefa de sumarização e como o fine-tuning adapta o modelo para essa aplicação específica.

6. **Questão 6.** Explique o conceito de "alucinação" em modelos de sumarização abstrativa. Por que esse fenômeno ocorre? Quais são seus impactos em aplicações reais e como ele pode ser mitigado?

BLOCO C — Análise de Sentimento

7. **Questão 7.** Compare as três abordagens para análise de sentimento: baseada em léxico, aprendizado de máquina clássico e deep learning. Para cada uma, descreva suas vantagens, limitações e o cenário ideal de aplicação.

8. **Questão 8.** Por que a negação é um desafio significativo para sistemas de análise de sentimento? Dê dois exemplos concretos onde a negação inverte o sentimento de uma frase e explique como modelos baseados em BERT lidam melhor com esse fenômeno em comparação com abordagens léxicas.

9. **Questão 9.** Por que o F1-Score é preferido ao Accuracy para avaliar modelos de análise de sentimento em datasets reais? Utilize um exemplo numérico para ilustrar uma situação em que a Accuracy seria enganosa.

BLOCO D — Integração e Análise Crítica

10. **Questão 10.** Projete um pipeline de PLN para o seguinte cenário: uma empresa brasileira deseja monitorar automaticamente notícias internacionais (em inglês) sobre seu setor, gerando diariamente um boletim em Português com os principais acontecimentos e o tom geral da cobertura. Descreva as etapas do pipeline, os modelos que utilizaria em cada etapa e como avaliaria a qualidade do sistema.

Material elaborado para o Curso de Processamento de Linguagem Natural