

Funcionamento do RAG com LLM

Este documento apresenta uma explicação detalhada sobre o funcionamento da arquitetura RAG (Retrieval-Augmented Generation) integrada a modelos de linguagem de grande porte (LLMs).




Figura 1 - Arquitetura de funcionamento do RAG

Visão Geral

O RAG combina técnicas de busca semântica com modelos generativos para permitir que uma LLM utilize informações externas durante a geração de respostas.

1. Indexação dos Documentos

Os documentos são utilizados como base de conhecimento. Esses documentos podem ser PDFs, arquivos TXT, páginas web, planilhas, artigos e bancos de dados.

Embeddings e Encoder Model

Os documentos passam por um modelo encoder responsável por converter textos em embeddings. Embeddings são representações vetoriais que capturam o significado semântico do texto.

Banco Vetorial

Os embeddings são armazenados em um banco vetorial, como ChromaDB, FAISS, Pinecone ou Qdrant. Esse banco permite realizar buscas semânticas eficientes.

2. Pergunta do Usuário

Quando o usuário realiza uma pergunta, ela também é transformada em embedding utilizando o mesmo modelo encoder.

Busca Semântica

O sistema compara o embedding da pergunta com os embeddings armazenados no banco vetorial para encontrar os documentos semanticamente mais relevantes.

k-Nearest Neighbors (k-NN)

O algoritmo k-NN seleciona os documentos mais próximos semanticamente da pergunta do usuário.

Contexto para a LLM

Os documentos recuperados são enviados como contexto para a LLM juntamente com a pergunta original.

Geração da Resposta

A LLM utiliza o contexto recuperado para gerar respostas mais precisas, reduzindo alucinações e melhorando a confiabilidade.

Vantagens do RAG

Entre as principais vantagens estão o uso de dados atualizados, redução de respostas inventadas, uso de documentos privados e menor custo computacional em comparação ao treinamento completo de uma LLM.

Pipeline Resumido

Documentos → Chunking → Embeddings → Banco Vetorial → Pergunta → Busca Semântica → Contexto → LLM → Resposta

Conclusão

O RAG transforma a forma como LLMs acessam conhecimento, permitindo que modelos generativos utilizem informações externas em tempo real para gerar respostas contextualizadas e confiáveis.